


Формат:

Задача 2 листок 0



к80 ш2.3.

ищем: $E_{x,y} [(y - E[y|x])^2]$ - ищем просто
или данные

сигнал увеличивается \Rightarrow где измен. тоже увеличивается,
на баз. уровне но это не очень страшно

разброс вырастет где
одной модели \Rightarrow где измен.

т.к. они более
сложными моделями

$$\text{Var}\left[\frac{1}{N} \sum b_i(x)\right] = \frac{\text{Var}(b_i(x))}{N} +$$

$$+ \frac{N(N-1)}{N^2} \underbrace{\text{Cov}(b_i, b_j)}_{\downarrow} \Rightarrow$$

\Rightarrow разброс где измен. \downarrow
т.к. корр. уменьшается

КР 0 2.5

$$\text{logreg: } \frac{1}{2} \sum \log(1 + e^{-y_i \langle x_i, w \rangle}) \rightarrow \min_w$$

$$\text{SVM: } \frac{1}{2} \|w\|^2 + C \sum \max(0, 1 - y_i \langle x_i, w \rangle) \rightarrow \min_w$$


регуляризация

у logreg меньше регуляризации, больше параметров

у SVM больше регуляризации ↗
параметров меньше ↘

Решение п. 2 по мере:

$$h(w) = \sum \mathbb{I}(w < 0) \quad , w = y_i \langle x_i, w \rangle$$



$$h(w) = \log(1 + e^{-w})$$

logreg

$$h_{\text{SVM}}(w) = \max(0, 1 - w)$$

у SVM больше регуляризации, но меньше параметров

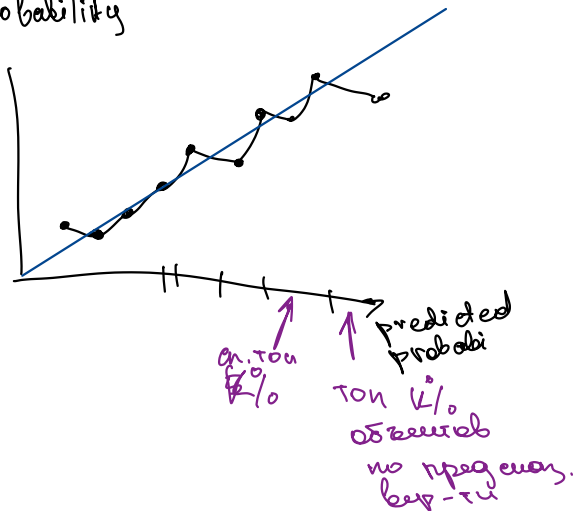
$$S_i^{(N)} = \frac{\partial}{\partial z} \ln(y_i, z) \Big|_{\substack{y=y_i \\ z=g(x_i) \\ N-1}}$$

- maybe you
ошибками N-ной
выборки в
VDS

↓
MSE

Матрица ковариаций

probability



SVD: преобразование век-ту

↓

$$b(x) : w \Rightarrow \langle w, x \rangle :$$

$$\begin{pmatrix} -100 \\ 10 \\ 20 \\ \vdots \end{pmatrix}$$

хотим
в век-ту

$$x_i = \langle w, x \rangle \in \mathbb{R}$$

⇓

гimme vector matrix на одной параллельной

(logres)

$$a(x) = z(\tilde{w}_0 + \tilde{w}_1 x) \quad , \quad \tilde{x} = \langle w, x \rangle$$

Probleme mit log

$$h_a(y, z) = \log(1 + e^{-yz})$$

$$h_b(y, z) = \max(0, 1 - yz)$$

$$h_c(y, z) = (yz - 1)^2$$

(1.1) One-vs-all

(1.2) $y = -1$

$$\operatorname{argmin}_{z \in \mathbb{R}} h(-1, z)$$

$$h_a: \log(1 + e^z) \rightarrow \min \Leftrightarrow z = -\infty$$

$$h_b: \max(0, 1 + z) \Rightarrow \min \Leftrightarrow z = -1$$

$$h_c: (-z - 1)^2 = (z + 1)^2 \rightarrow \min \Leftrightarrow z = -1$$

(1.3)

$$a(x) = \operatorname{sign}(\langle w, x \rangle)$$

$$\tilde{a}(x) = \operatorname{sign}(\langle w, x \rangle - 10)$$


$$h_a: \log(1 + e^{-y(\langle w, x \rangle - 10)}) \quad \text{q-2 normal}$$

$$h_b: \max(0, 1 - y(\langle w, x \rangle - 10)) \quad \text{margin}$$

$$\langle w, x \rangle = 100 \Rightarrow$$

$$\max(0, 1 - 100) = 0 \quad \max(0, 1 - 90) = 0$$

1.5.1



$$\|w\|^2 + C \sum_{i=1}^l \xi_i \rightarrow \min$$

чем меньше $\|w\|$, тем больше регуляризатор

Если $C \rightarrow \infty$, то модель может переобучиться

2

2.1 out-of-bag

2.2

$$\frac{1}{l} \sum_{i=1}^l \frac{(b_N(x_i) - s_i)^2}{2(s_i - b_N(x_i))} \rightarrow \min_{b_N}$$

grad-boost.

$$s_i = \frac{\partial L(y_i, z)}{\partial z} \Big|_{z = b_{N-1}(x_i)}$$

↑
градиент по z , т.е. антиградиент

$z = b_{N-1}(x_i)$
 $a_{N-1}(x_i)$

Где s_i — это?

2.3

$$y_i > 0$$

$a(x) < 0$ где реш. задачи на MSE

Нет, т.е. реш. задачи на MSE удерж. промисла \Rightarrow среднее > 0

Случ. лес тоже нет, т.е. ср. промоз

На граф. бюджетные могут, т.е. там елки

2.2) $\sum_{j=1}^N y_j^2$ - нельзя такой пер. в отдельном дереве
объясн.

т.е. он запрещает появление беса

3.1) error rate \rightarrow with

"
 $\frac{1}{L} \sum \mathbb{I} a(x_i) \neq y_i \rightarrow \min$
нельзя граф., поэтому не
используем

3.2) γ_+ : не пересекать минимизм

max t: $\begin{matrix} \text{доп. см} \uparrow \\ \text{погр. см} \uparrow \end{matrix}$

Не может, т.е. мы уменьшаем погр. см.

$\begin{matrix} \text{доп. см} \uparrow \\ \text{погр. см} \downarrow \end{matrix}$ - может

3.3)
 $z \geq y \quad \log \cosh(z-y)$
 $z < y \quad \log \cosh(z-y)$

3.9) $\sum_{j=1}^d |w_j|^2$ - сильно накл. за сумму весов

$\max_{j=1, \dots, d} |w_j|$ - не дифф

$\sum_{i=1}^d [w_i \neq 0]$ - считать пересек., но мин. x_i или т.е. не дифф.

4) $x_i \sim \mathcal{N}(0, \sigma^2)$

$y_i = \varepsilon_i x_i$

$\varepsilon_i \sim \text{Exp}(\lambda)$

$\mu(x) = \frac{1}{\lambda \ell} \left(\sum_{i=1}^{\ell} x_i \right) \text{sign}(x)$

$\mathbb{E}[y|x] = \mathbb{E}[\varepsilon x|x] = x \mathbb{E}[\varepsilon|x] = x \cdot \frac{1}{\lambda} = \frac{x}{\lambda}$

noise: $\mathbb{E}_{x,y} [y - \mathbb{E}[y|x]]^2 =$

$$= \mathbb{E}_{x,y} \left[y - \frac{x}{\lambda} \right]^2 = \mathbb{E}_{x,y} \left[\varepsilon x - \frac{x}{\lambda} \right]^2 = \underbrace{\mathbb{E}[x]^2}_{0^2} \cdot \underbrace{\mathbb{E} \left[\varepsilon - \frac{1}{\lambda} \right]^2}_{\left(\mathbb{E}[\varepsilon] - \mathbb{E}[\varepsilon] \right)^2 = \text{Var}[\varepsilon] = \frac{1}{\lambda^2}} =$$

$$= \frac{\sigma^2}{\lambda^2}$$

bias:

$\mathbb{E}_x [\mu(x)] = \mathbb{E}_x \left[\frac{1}{\lambda \ell} \left(\sum x_i \right) \text{sign}(x) \right] = \frac{1}{\lambda \ell} \text{sign}(x) \sum \mathbb{E}[x_i] = 0$
оп. несмещ.

$$\text{bias} = \mathbb{E}_x \left[\underbrace{\mathbb{E}_x [\mu(x)]}_{\text{cp. wegen}} - \underbrace{\mathbb{E} [y|x]}_{\substack{\text{Nur.} \\ \text{wegen}}} \right]^2 =$$

$$= \mathbb{E}_x \left[0 - \frac{x}{\lambda} \right]^2 = \frac{1}{\lambda^2} \mathbb{E}_x [x^2] = \frac{\sigma^2}{\lambda^2}$$

" $\text{Var} - (\mathbb{E}[x])^2 = \sigma^2 - 0$

variance:

$$\mathbb{E}_{x,x} \left(\underbrace{\mathbb{E} [y(x)] + \mathbb{E} [1]}_{\substack{\text{Nur.} \\ \text{wegen}}} \right)^2 = \mathbb{E}_{x,x} \left[\frac{1}{\lambda^2 \ell} \left(\sum x_i \right) \text{sign}(x) \right]^2 =$$

$$= \frac{1}{\lambda^2 \ell^2} \underbrace{\mathbb{E}_x [\text{sign}^2(x)]}_1 \mathbb{E}_x \left[\sum x_i \right]^2 =$$

$$= \frac{\ell}{\lambda^2 \ell^2} \left(\underbrace{\sum_{i \neq j} \mathbb{E} x_i x_j}_{\substack{\text{Nur.} \\ \mathbb{E} x_i \cdot \mathbb{E} x_j = 0 \\ \text{"0"} \quad \text{"0"}}} + \underbrace{\sum_{i=1}^{\ell} \mathbb{E} x_i^2}_{\substack{\text{"}\sigma^2\text{"} \\ \lambda \sigma^2}} \right) = \frac{\sigma^2}{\lambda^2 \ell}$$

